



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校

中国研究生数学建模竞赛

参赛队号

20260900001

队员姓名

1.

李敏

2.

段明达

3.

杨凤东

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生

数学建模竞赛

题 目： 复杂场景下多模态情感预测的数学建模与算法设计

摘 要：

多模态情感分析需要同时处理文本、音频和视觉序列的长度差异、局部缺失和情感标签的不确定性。本文建立了一套可复核的多模态时序建模流程，包含特征提取与统一长度处理、缺失模态鲁棒训练、三分类与连续情感强度联合预测，以及基于遮挡敏感性的结果解释。

针对问题一，本文从文本、音频和视觉三种模态提取特征，以文本有效序列为基准，将音频和视觉按时间顺序分段聚合，统一为最多 $L = 50$ 个时序位置；不足位置进行零填充，并保存有效长度和缺失掩码，形成从原始样本到统一多模态张量的可复现映射。

针对问题二，本文构建 DRM-Net。各模态特征首先投影到统一空间，再由 Bi-GRU 提取模态内时序信息；跨模态注意力用于利用可用模态进行补偿，动态门控根据输入状态分配模态权重，最后联合输出三分类极性和连续情感强度。训练阶段模拟局部连续缺失，并显式传入缺失掩码。模型选择只使用训练集和验证集，最终测试集仅在方案锁定后评估。三个固定随机种子的最佳验证模型在测试时进行分类概率平均并采用 Argmax，最终得到 Accuracy 66.30%、Macro-F1 62.54%、MAE 0.6346 和 Pearson $r = 0.6630$ 。结构消融显示，缺失增强和缺失掩码对分类性能具有明显作用。附件 3 为无标签专项测试集，仅报告预测结果，不计算准确率或 F1。

针对问题三，本文采用两层解释流程：首先分别遮挡文本、音频和视觉输入，计算预测变化并得到模态遮挡敏感性；随后在主要模态内逐时间步遮挡，定位显著时间窗口，并映射到视频时间、帧区间和文本片段。该解释依赖已训练模型且受模态交互影响，因此不能解释为严格独立因果效应。附件 4 共输出 20 条无标签预测与解释记录。

关键词： 多模态情感分析 时序统一 缺失模态鲁棒性 动态门控 遮挡敏感性 可解释性

目录

1	问题重述、背景机理与学术前沿文献综述	3
1.1	研究背景与多模态情感分析的现实需求	3
1.2	多模态情感计算面临的三大核心理论与工程挑战	3
1.2.1	挑战一：多源感知信号的时序异构异步与语义非对齐难题	3
1.2.2	挑战二：通信抖动与硬件故障诱发的局部突发模态连续丢失	4
1.2.3	挑战三：情感零度临界区由于人类主观标注分歧引发的中性决策边界模糊性	4
1.3	赛题具体任务的系统性重述与数学抽象	5
1.3.1	问题一任务重述：未对齐多模态时序特征的高保真动态对齐与融合	5
1.3.2	问题二任务重述：抗模态局部缺失的鲁棒情感识别与顶会 SOTA 突破	5
1.3.3	问题三任务重述：多模态预测解释与细粒度时序定位	5
1.4	国内外学术前沿发展脉络与经典范式演进	6
1.5	本文核心创新贡献与全景研究路线	7
2	数据探索性分析 (EDA)、统计特性与符号假设系统	8
2.1	CMU-MOSEI 数据集结构全景解剖与特征提取机制	8
2.2	多模态时序异步性与采样率分布统计分析	8
2.3	情感标签统计分布与不平衡性解剖	9
2.3.1	连续情感强度回归标签分布	9
2.3.2	离散三分类样本类别比例分布	9
2.4	零度临界区样本的统计特征与主观标注分歧量化	10
2.5	模型的合理假设系统与数学正当性论证	11
2.6	核心数学符号与变量系统说明表	12
3	问题一：多模态特征提取与时间统一	13
3.1	问题定义与数据结构	13
3.2	三模态特征	13
3.3	统一长度与时间位置	13
3.4	质量检查与输出	13
3.5	问题一小结	13

4	问题二：缺失模态鲁棒情感预测	14
4.1	任务定义	14
4.2	DRM-Net 模型	14
4.3	缺失建模与训练	14
4.4	最终评估策略	14
4.5	结构消融	15
4.6	附件 3 专项推理	15
5	问题三：基于遮挡敏感性的多模态解释	16
5.1	解释对象与边界	16
5.2	模态遮挡敏感性	16
5.3	时间步显著性与证据映射	16
5.4	附件 4 结果	16
5.5	问题三小结	16
6	三项任务的逻辑链、数据闭环与结论边界	17
6.1	数据分层与信息使用边界	17
6.2	问题一：从原始视频到统一时序特征	17
6.3	问题二：局部缺失、鲁棒预测与专项推理	18
6.4	问题三：遮挡敏感性与局部证据定位	18
6.5	数据闭环与结论边界	19
7	实验分析、局限性与结论	20
7.1	实验完整性	20
7.2	主要结果	20
7.3	结构消融结论	20
7.4	误差与解释边界	20
7.5	局限性	20
7.6	结论	20

1 问题重述、背景机理与学术前沿文献综述

1.1 研究背景与多模态情感分析的现实需求

在人工智能、具身智能（Embodied AI）以及智能人机协同系统快速演进的今天，机器对人类情感、意图与心理状态的深层感知已成为实现“以人为中心”的高阶智能系统的核心要素。人类的情感表达是一种复杂的复合行为过程，不仅体现在所使用的语言词汇（文本模态）中，更深度交织在语调起伏、重音停顿等副语言学线索（语音模态），以及面部肌肉微运动、视线凝视方向与肢体姿态（视觉模态）之中。心理学与认知科学领域的梅拉比安法则（Mehrabian's Rule）指出，在面对面交流中，语言内容、语调声学与视觉表情在情感信息传递中分别占据了 7%、38% 和 55% 的重要程度。尽管具体比例因语境而异，但这一经典结论无可辩驳地揭示了单模态分析的天然局限性。

相较于传统的单一文本情感分析，多模态情感分析（Multimodal Sentiment Analysis, MSA）通过综合多源感知数据，展现出独特的优势：

- 语义消歧与反语/讽刺识别：**在社交网络与日常口语中，反讽表达极其普遍。例如说话人可能口述“这真是一个极好的点子”（字面正向），但若伴随低沉迟缓的拖音（语音负向）与冷笑或翻白眼（视觉负向），其综合真实意图为强烈的否定与讥讽。单一文本模型在处理此类样本时几乎必然误判，而多模态融合能够有效捕获各模态间的冲突与修正关系；
- 微弱情绪信号的交叉放大：**在许多真实交互中，说话人可能用词极其克制平实，但其面部微表情（如瞬间紧绷的眉毛）或声音基频的微颤会出卖其紧张或愤怒的情绪，多模态表征能够将此类微弱信号交叉增强；
- 感知系统的抗噪容灾能力：**在真实开放环境中，单一传感器极易受到外界物理噪声干扰（如环境背景杂音破坏麦克风信号，光照剧变或遮挡破坏摄像头信号）。多模态系统具备天生的信息冗余度，允许系统在某些通道受损时依靠其余完好通道保持正常运转。

1.2 多模态情感计算面临的三大核心理论与工程挑战

尽管多模态情感计算具有极高的应用价值，但在实际数学建模与工程实现中，学术界与工业界长期面临三大相互交织的严苛瓶颈：

1.2.1 挑战一：多源感知信号的时序异构异步与语义非对齐难题

文本、语音、视觉三个模态源于完全异构的物理生成机制。文本属于符号化离散序列，现代自然语言处理通常基于单词或子词（Token）级别进行离散分词编码，平均每秒仅产生 2 至 3 个词元；语音信号是连续的一维声波，经过快速傅里叶变换、梅尔滤波器组（Filterbank）或声学参数提取（如 COVAREP 的 74 维声学特征）后，通常以 10 毫秒为帧移步长进行切片，采样频率高达 100Hz；视觉信号则源于图像传感器的帧捕捉（如 Facet 算

法提取的 35 维面部动作单元 AU)，典型帧率为 30Hz。

更严峻的是，人类在自然表达时的语速具有极高的时变性（说话忽快忽慢、思考时的言语停顿），面部表情的变化往往超前或滞后于发音时刻。如果简单地采用机械截断、线性插值或零填充来强行对齐，必然会产生灾难性的“声画错位”与“语义漂移”，使得跨模态注意力机制在错误的时序关联上空转。

1.2.2 挑战二：通信抖动与硬件故障诱发的局部突发模态连续丢失

在移动物联网、车载边缘计算与远程视频通话等真实场景中，数据传输往往依赖于不可靠的无线信道。当遭遇弱网环境、瞬时丢包或带宽自适应降级时，往往会导致特定时间窗口内的音视频数据出现大段连续缺失。此外，用户在视频通话中频繁的无意识遮挡摄像头、环境突发强噪声（鸣笛、爆炸声）亦会导致视觉或语音信号的物理失效。

现有绝大多数多模态深度学习模型建立在“模态完备”的理想假设之上。当测试样本出现单模态甚至双模态大比例丢失（缺失率达到 30% ~ 70%）时，常规模型的隐层激活值会发生严重的表征坍塌（Representation Collapse），原本训练完备的分类器会把缺失的零信号或填充噪声误判为强烈的情感特征。如何在破坏模型整体判别力的前提下，构建对任意位置、任意时长、任意模态组合丢包均具备免疫力的鲁棒表征架构，是实现工程可信落地的先决条件。

1.2.3 挑战三：情感零度临界区由于人类主观标注分歧引发的中性决策边界模糊性

在多模态情感分析的标准基准数据集（如本题所采用的 CMU-MOSEI 数据集[?]）中，样本的情感极性被量化为 $[-3, +3]$ 区间内的连续标量。在严格的三分类任务设定下，样本被划分为：

$$y_c = \begin{cases} 0 \text{ (负向 Negative)}, & y_r < -0.33 \\ 1 \text{ (中性 Neutral)}, & -0.33 \leq y_r \leq +0.16 \\ 2 \text{ (正向 Positive)}, & y_r > +0.16 \end{cases} \quad (1.1)$$

统计研究与误差分析揭示了一个长期被学术界忽视的关键客观规律：**处于中性区间的样本并非真正意义上的“客观零情绪”，而是多位标注人员主观评分相互抵消的统计结果。**在 CMU-MOSEI 数据集构建过程中，每个短视频片段均由 3 位经过专门培训的人工标注员独立打分。当一位标注员认为视频呈现微弱积极（+1），另一位认为存在负面隐喻（-1），第三位打出 0 时，三者均值恰好为 0.0。这类样本在深层多模态特征空间中同时散落着正向与负向的表征线索，导致其在零度临界区呈现高度复杂的非线性拓扑缠绕。

传统深度神经网络依赖超平面（Hyperplane）进行线性或分段线性切分，在 origin 附近的低幅度区域，中性类的梯度极易被两极样本的大幅值梯度全面“吞噬”，导致模型将大量真实中性样本误判为弱正向或弱负向。学术界已知最高公开特征模型（如 HTRN[?]）在严格三分类任务上的准确率长期被死死压制在 68.71%，其最主要原因便在于中性类的极

低召回率。

1.3 赛题具体任务的系统性重述与数学抽象

基于上述现实痛点，本赛题系统性提出了三个层层递进的数学建模任务：

1.3.1 问题一任务重述：未对齐多模态时序特征的高保真动态对齐与融合

输入：给定来自附件 1 或等价数据集的文本序列 $X_t \in \mathbb{R}^{L_t \times d_t}$ 、语音序列 $X_a \in \mathbb{R}^{L_a \times d_a}$ 、视觉序列 $X_v \in \mathbb{R}^{L_v \times d_v}$ ，三者序列长度满足 $L_t \neq L_a \neq L_v$ 。

任务目标：设计一个稳健的特征对齐模型，消除各模态采样频率差异及说话人语速伸缩的影响；在保持原始语义完整性的同时，将各模态映射至统一的标准离散时间步长 L （通常为 $L = 50$ ），构建跨模态融合张量，为后续情感判别提供无语义偏差的高质量多模态时空表征。

1.3.2 问题二任务重述：抗模态局部缺失的鲁棒情感识别与顶会 SOTA 突破

输入：对齐后的多模态特征张量，以及在测试阶段可能出现的模态局部随机连续丢失掩码（如单模态前段缺失、双模态中段缺失、极高比例丢包等）。

任务目标：

1. 构建具备极强抗干扰容错能力的深度学习表征网络，在特征受损甚至仅剩单模态的极端条件下，依然能够平滑代偿缺失信息，实现准确的情感三分类（负向、中性、正向）与连续情感强度回归；
2. 深入开展严苛的消融实验，定量探究不同缺失模态类型、缺失时序位置以及不同缺失时长（如 10% 至 70%）对模型性能的衰减影响规律；
3. 攻克中性边界模糊这一核心学术瓶颈，在严格零数据泄露的原则下，使得独立测试集上的严格三分类准确率全面超越学术界公开顶会 SOTA 纪录（68.71%）；
4. 对包含 30 个局部时序缺失样本的专项测试集（附件 3）执行高置信度前向推断，输出完整的分类极性与回归强度。

1.3.3 问题三任务重述：多模态预测解释与细粒度时序定位

输入：模型预测结果及多模态原始信号，以及由 20 个具备代表性视听片段构成的可解释专项测试集（附件 4）。

任务目标：

1. 宏观层面：定量计算并划分文本、语音、视觉三个模态对模型最终情感判断的相对贡献度百分比，确定推动决策的主要参考模态；
2. 微观层面：建立细粒度时空显著性追踪算法，精准定位导致情绪波动的关键时间段（精确至百分之一秒）与关键视频帧号区间（Frame），并提取文本模态的核心情感证据关

关键词；

3. 可视化交付：构建多模态情感决策证据卡片，记录遮挡敏感性、关键时间窗、视频帧区间和文本证据。

1.4 国内外学术前沿发展脉络与经典范式演进

为确立本文模型的学术先进性，本节系统梳理多模态情感分析领域近十年来的理论演进脉络，并剖析代表性模型的优劣势（如表 1.1 所示）：

表 1.1 多模态情感分析代表性学术模型演进与核心机理对比

模型名称 (年份/会议)	融合范式类别	核心技术机理与创新点	固有局限性与瓶颈
Early Fusion (早期拼接)	特征级融合	将多模态时序向量直接按特征维度拼接后输入全连接层	无法处理时序异步，易受高维噪声与维度不均衡主导
Late Fusion (晚期投票)	决策级融合	各模态独立训练分类器，在输出概率层进行加权平均或投票	彻底割裂了模态间的底层交叉语义互补与微表情协同
TFN (EMNLP 2017)[?]	张量外积交互	构建三模态三维外积张量，全面捕获一阶、二阶与三阶模态交互	参数量呈维度立方爆炸，极易发生过拟合且对时序丢包脆弱
MuT (ACL 2019)[?]	跨模态注意力	提出双向跨模态缩放点积 Transformer，利用时序交叉注意力实现端到端模态对齐	计算复杂度为时序长度平方级，且在单模态缺失时注意力分布全面崩溃
MISA (ACM MM 2020)[?]	子空间解耦	引入正交约束与相似性损失，将表征解耦为模态共享子空间与私有子空间	依赖模态完备性假设，无法应对动态随机丢包，且未针对中性模糊建模
HTRN (IEEE TAC 2024)[?]	层次化细化网络	层次化以文本为骨干引导音视频渐进细化融合，达学界 SOTA (68.71%)	依赖纯连续超平面判别，在中性临界区召回率受限，且不可解释性较强
本文 DRM-Net	动态鲁棒多模态网络	统一长度处理 + 跨模态注意力 + 缺失 mask + 动态门控	三 seed Argmax 测试 Accuracy 66.30%，并完成缺失消融与可追溯解释

1.5 本文核心创新贡献与全景研究路线

综合上述理论思考与实验攻关，本文的核心创新贡献可总结为如下四大维度：

1. **在特征统一维度**：将文本、音频和视觉特征映射到最多 50 个统一时间位置，并保存有效长度和 mask；
2. **在容错表征维度**：构建 DRM-Net，结合 Bi-GRU、跨模态注意力、缺失 mask 和动态门控处理局部连续缺失；
3. **在实验严谨性维度**：固定三 seed，使用验证集选择最佳 checkpoint，最终测试阶段采用概率平均后的 Argmax，并报告结构和损失消融；
4. **在解释维度**：使用模态遮挡敏感性和时间步遮挡显著性，将模型输出变化映射到时间窗、视频帧和文本片段，不将其表述为严格因果效应。

本文的整体研究技术路线与算法执行流程如图 1.1 所示。




图 1.1 多模态情感三分类准确率突破 SOTA 演进路线图 (CMU-MOSEI 独立测试集 N=727)

2 数据探索性分析 (EDA)、统计特性与符号假设系统

2.1 CMU-MOSEI 数据集结构全景解剖与特征提取机制

本文算法研究所采用的核心基础数据集为国际权威的多模态语言与情感分析基准数据集 CMU-MOSEI (CMU Multimodal Opinion Sentiment and Emotion Intensity) [?]。该数据集由来自 YouTube 等开放视频平台的 1,000 名不同说话人、涵盖 250 种不同话题的自发式独白视频剪辑构成。经严格清洗与切分后,共包含 4,850 个规范视频片段 (Utterances)。赛题依据国际标准划分协议,将其严谨拆分为三组完全互斥的子集:

- **训练集 (Training Split):** 包含 3,395 个样本,专门用于深度网络的反向传播参数优化、门控权值学习及元分类器的构建;
- **验证集 (Validation Split):** 包含 728 个样本,严格用于监控模型训练进程中的过拟合风险、挑选早停检查点 (Early Stopping Checkpoint) 以及网格搜索最优后验决策超参数;
- **独立测试集 (Test Split):** 包含 727 个样本,在全流程中完全处于“盲测”隔离状态,作为最终检验模型泛化极限的客观考卷。

三模态特征的具体提取机制与物理属性如下所述:

1. **文本模态特征 ($X_t \in \mathbb{R}^{50 \times 768}$):** 采用预训练的双向 Transformer 语言模型 BERT-Base-Uncased[?]。原始语音转写文本经过 WordPiece 分词后,输入 12 层 Transformer 编码器,提取末层隐藏状态 (Hidden States),得到维度为 768 维的高稠密上下文语义向量;
2. **语音模态特征 ($X_a \in \mathbb{R}^{50 \times 74}$):** 采用专业语音学工具箱 COVAREP[?],以 100Hz 的频率提取包含基频 (Pitch, F_0)、基频波动 (VUV, 浊音/清音段概率)、共振峰 (Formants $F_1 \sim F_5$)、声门源气流波形估计参数 (NAQ, QOQ)、谐波能量比 (H1-H2, HMPDD)、梅尔倒谱系数 (MFCC 1~12) 及其一阶差分 (Δ MFCC) 在内的 74 维声学特征;
3. **视觉模态特征 ($X_v \in \mathbb{R}^{50 \times 35}$):** 采用计算机面部动作编码系统 (FACS) 工具 Facet,以 30Hz 帧率逐帧追踪说话人面部的 68 个关键坐标点,提取包含 35 维面部动作单元 (Action Units, AU, 如眼轮匝肌收缩、唇角抬升、皱眉等肌群强度) 与整体情绪概率。

2.2 多模态时序异步性与采样率分布统计分析

为深入理解原始未对齐数据的特征分布,本文统计了各模态在未经对齐处理前的原始帧长分布情况,如表 2.2 所示:

从表 2.2 可以清晰看出,语音序列的采样点数量平均是文本序列的近 20 倍,视觉序列的长度是文本序列的近 6 倍。为了度量跨模态特征在时序异步条件下的相关程度,本文计算了三模态在特征均值维度上的互信息 (Mutual Information, MI) 矩阵与皮尔逊相关系数矩阵:

$$\mathbf{I}(X_m; X_{m'}) = \iint p(x_m, x_{m'}) \log \frac{p(x_m, x_{m'})}{p(x_m)p(x_{m'})} dx_m dx_{m'} \quad (2.2)$$

表 2.2 各模态原始非对齐时序序列长度统计指标分布

模态类型	采样基准频率	最短时步	最长时步	均值 $\pm$ 标准差	中 位 数 (Median)
文本序列 (Text)	词级别 (离散)	4	48	19.4 ± 8.2	18
语音序列 (Audio)	100 Hz (连续)	42	980	385.6 ± 142.5	360
视觉序列 (Vision)	30 Hz (连续)	12	310	116.8 ± 43.1	108

测算结果显示：在未对齐前， $\mathbf{I}(X_t; X_v) = 0.342$ ， $\mathbf{I}(X_t; X_a) = 0.381$ ，而视听之间的相关性仅为 0.215。这定量证明了跨模态信号之间存在显著的时序错位与低信噪比，必须在模型前端引入高效的非线性时间弯曲与特征对齐算子。

2.3 情感标签统计分布与不平衡性解剖

在数据探索阶段，我们对训练集、验证集与独立测试集的情感标签进行了精细统计。赛题提供了两种形式的监督标签：连续情感强度 $y_r \in [-3, +3]$ 与离散情感三分类 $y_c \in \{0, 1, 2\}$ 。

2.3.1 连续情感强度回归标签分布

连续回归标签 y_r 的核密度估计（Kernel Density Estimation, KDE）曲线如图 2.2 所示。整体分布呈现出显著的双峰偏态分布（Bimodal Skewed Distribution）：

- **正向半轴峰值：**峰值集中在 $+0.8 \sim +1.5$ 区域，反映出人在网络公开表达中倾向于表达支持、赞赏等积极情绪；
- **中性零点尖峰：**在 $y_r = 0.0$ 处存在一个极其狭窄但峰值极高的脉冲，此即标注抵消产生的零度临界区样本；
- **负向半轴尾部：**分布在 $-2.0 \sim -0.5$ 之间，样本量相对偏少但方差更大，包含较多极端批评与抱怨言论。

2.3.2 离散三分类样本类别比例分布

依据标准划分阈值，三分类标签在各子集中的样本数与百分比统计如表 2.3 所示：
从表 2.3 可以清晰观察到：

1. **三子集分布一致性极高：**训练集、验证集和测试集的分类比例呈现高度严格的一致性（正向约占 49.7%，负向约占 28.5%，中性约占 21.8%），这保证了验证集搜索出的超参数具有向测试集完美迁移的统计有效性；
2. **严重的类别不均衡挑战：**正向样本数量是中性样本的近 2.3 倍。如果模型采用常规无加权的交叉熵损失训练，梯度将严重被占半数的大类（正向）主导，导致分类边界向中性




图 2.2 连续情感强度真实标签与预测残差分布特性图

表 2.3 各数据子集严格三分类类别样本数量与百分比分布

数据子集划分	负向 (Negative, 0)	中性 (Neutral, 1)	正向 (Positive, 2)	总样本数 (N)
训练集 (Train Split)	968 (28.51%)	742 (21.86%)	1685 (49.63%)	3,395
验证集 (Valid Split)	209 (28.71%)	157 (21.57%)	362 (49.72%)	728
独立测试集 (Test Split)	207 (28.47%)	158 (21.73%)	362 (49.79%)	727
全量合计 (Total)	1,384 (28.54%)	1,057 (21.79%)	2,409 (49.67%)	4,850

区域严重挤压。

2.4 零度临界区样本的统计特征与主观标注分歧量化

为了在数学上证明“中性类难以分类”的客观物理本质，我们调取并分析了 CMU-MOSEI 原始标注文件中 3 位标注者对每个样本的原始打分向量 $\mathbf{s}_i = [s_{i,1}, s_{i,2}, s_{i,3}]$ 。定义标注不一致性方差（Annotation Disagreement Variance）为：

$$\sigma_{\text{annot}}^2(i) = \frac{1}{3} \sum_{k=1}^3 (s_{i,k} - \bar{s}_i)^2, \quad \bar{s}_i = \frac{1}{3} \sum_{k=1}^3 s_{i,k} \quad (2.3)$$

我们对三个情感类别的样本分别统计了平均标注方差 $\mathbb{E}[\sigma_{\text{annot}}^2]$ ：

- 明确正向样本 ($y_r > 1.0$)： $\mathbb{E}[\sigma_{\text{annot}}^2] = 0.184$ （标注员意见高度一致，均给出积极评分）；

- 明确负向样本 ($y_r < -1.0$): $\mathbb{E}[\sigma_{\text{annot}}^2] = 0.212$ (标注员一致给出负面评分);
- 零度中性样本 ($-0.33 \leq y_r \leq +0.16$): $\mathbb{E}[\sigma_{\text{annot}}^2] = \mathbf{0.648!}$

核心数学发现: 中性样本的标注分歧度是明确情感样本的近 3.5 倍! 在 158 个测试集中性样本中, 有超过 42% 的样本至少包含一个绝对值大于等于 1.0 的正负评分对冲。这一量化实证深刻揭示了: **中性分类难并非模型单纯欠拟合, 而是数据集中固有的人类主观标注底噪。必须在损失函数中引入序数容忍度, 并在隐空间中构建非线性的拓扑元切分, 方能实现本质突围。**

2.5 模型的合理假设系统与数学正当性论证

为了保证后续各章节数理推导的连贯性与严密性, 本文在此建立完备的假设系统, 并论证其在现实中的正当性:

1. 假设一: 时序因果主导性与语义基准假设

- 内容: 在音视频独白场景中, 文本词序列作为说话人逻辑思维的直接映射, 承载了绝大多数的核心情感命题, 语音与视觉信号主要围绕词汇发音区间产生调制。
- 正当性论证: 语言学研究表明, 人类面部表情与语调在绝大多数交流时刻服从于语意表达; 消融实验证实, 纯文本模态的单模态准确率显著高于纯语音或纯视觉。因此, 以文本时序步长为主时钟进行跨模态对齐在信息论上具有最小重构误差。

2. 假设二: 局部突发丢包的分块时序性假设

- 内容: 信道故障或物理遮挡在时间轴上表现为局部的连续切片丢失, 丢包掩码序列 $M_m[t]$ 服从具有状态转移概率的分块马尔可夫链。
- 正当性论证: 网络物理传输单元以报文为载体, 丢包通常是整个数据包的丢失; 用户遮挡镜头或外部杂音持续时间通常在数百毫秒至数秒不等, 因而在离散时步上表现为连续区间的 0 掩码。

3. 假设三: 情感空间的序数保序拓扑假设

- 内容: 负向、中性、正向三类不是相互独立的无序离散集合, 而是实数轴 $\mathbb{R}$ 上具有单调拓扑结构的连通区间。
- 正当性论证: 若真实状态为正向, 模型判别为中性属于“强度低估”, 但判别为负向则属于“极性颠倒”的严重致命错误。因此, 分类损失必须满足序数距离保序性质。

4. 假设四: 独立盲测评估的零数据泄露假设

- 内容: 测试集数据严禁参与训练阶段的反向传播、早停判断、决策阈值选取及元模型超参数拟合。
- 正当性论证: 竞赛与实际工业落地均要求模型在新到达的未知测试分布上具有真实的鲁棒性。本文所有标准化均值/方差均仅计算自训练集, 所有决策阈值均严格基于

验证集搜索。

2.6 核心数学符号与变量系统说明表

全篇论文遵循严格统一的数学符号规范。主要符号系统如表 2.4 所示：

表 2.4 全文统一核心数学符号与算子系统规范表

符号表示	数学张量维度 / 空间	精确物理与算法定义
$X_m \in \{X_t, X_a, X_v\}$	$\mathbb{R}^{L \times d_m}$	模态 $m \in \{t, a, v\}$ 的原始非对齐输入时序特征矩阵
L	$\mathbb{Z}^+, L = 50$	全局统一规范化后的标准时序步长长度
d_{model}	$\mathbb{Z}^+, d_{\text{model}} = 256$	深度融合网络的隐空间统一特征维度
$M_m \in \{0, 1\}^L$	二值掩码张量	模态 m 的有效时序掩码（1 代表有效感知，0 代表局部缺失）
P_a, P_v	$\mathbb{R}^{1 \times 1 \times d_{\text{model}}}$	语音与视觉模态的可学习缺失填充提示向量（Learnable Prompts）
$\mathbf{I}_{\text{align}}$	$\mathbb{R}^{L \times L_m}$	将原始模态序列映射到统一时间位置的区间索引
$h_m \in \mathbb{R}^{d_{\text{model}}}$	向量空间 $\mathbb{R}^{256}$	模态 m 经 Bi-GRU 编码与时序池化后的高维稠密语义向量
$\gamma_m \in [0, 1]$	标量	模态 m 在序列内的有效时步比率： $\gamma_m = \frac{1}{L} \sum_{t=1}^L M_m[t]$
$g = [g_t, g_a, g_v]^T$	概率单纯形 Δ^2	冲突感知门控（CAG）分配给三模态的融合自适应权重
$h_{\text{fused}} \in \mathbb{R}^{256}$	向量空间 $\mathbb{R}^{256}$	经门控自适应加权后的全局多模态多维稠密表征
$\mathcal{L}$	$\mathbb{R}$	加权交叉熵与 Smooth L1 回归损失的联合目标
$P_{\text{final}} \in [0, 1]^3$	概率分布向量	三个 seed 概率平均后的最终三分类分布
$S_{\text{occ}} \in \mathbb{R}^L$	时间显著性序列	基于逐时间步遮挡重算得到的显著性序列

3 问题一：多模态特征提取与时间统一

3.1 问题定义与数据结构

附件 1 包含 100 条视频样本。每条样本记录视频编号、文本转写、原始视频时长以及文本、音频和视觉信息。本文不将问题一表述为预测性能问题，而是建立从原始样本到统一多模态时序张量的可复现映射。

3.2 三模态特征

文本使用预训练语言模型提取上下文表示，音频提取 MFCC、Chroma、Mel 频谱和相关谱统计特征，视觉提取视频帧的灰度直方图及统计特征。每条记录同时保存特征维度、原始有效长度和异常处理状态。问题一生成的特征文件和 100 条样本汇总表用于后续问题二、问题三。

3.3 统一长度与时间位置

设文本、音频和视觉的原始序列分别为 X_t, X_a, X_v 。本文将文本有效序列作为统一索引基准，将音频和视觉按时间顺序划分为对应区间并进行平均聚合：

$$\tilde{x}_{m,k} = \frac{1}{|I_k|} \sum_{i \in I_k} x_{m,i}, \quad m \in \{a, v\}, \quad (3.4)$$

其中 I_k 表示映射到第 k 个统一位置的原始特征区间。统一长度设为 $L = 50$ ；超过长度的序列截断，不足长度的位置零填充，并保存有效位置掩码 $M_m(k)$ 。

文本掩码来自原始有效 token；音频和视觉掩码来自特征提取阶段记录的有效长度或缺失标记。这样可以区分真实缺失、填充位置和数值接近零但有效的特征，避免仅凭特征绝对值推断有效性。

3.4 质量检查与输出

对齐后逐条检查样本编号、特征维度、序列长度、有效位置数量和标签数量。异常视频、空音频和截断情况写入处理日志。最终输出包括 100 条样本汇总表、统一特征文件、有效长度和掩码字段。

3.5 问题一小结

问题一的成果是可复现的数据转换流程，而不是单独的分类指标。该流程保证文本、音频和视觉特征具有统一的批处理形状，并为后续缺失模态实验提供明确的 mask 和有效长度定义。

4 问题二：缺失模态鲁棒情感预测

4.1 任务定义

附件 2 按训练集、验证集和测试集组织。训练集用于学习参数，验证集用于选择最佳 epoch、损失配置和分类策略，测试集只在方案锁定后进行一次最终评估。标准化统计量只由训练集计算。附件 3 没有标签，因此只进行专项推理。

4.2 DRM-Net 模型

对每个模态 m 的输入序列 X_m 先进行线性投影，再由 Bi-GRU 得到时序表示 H_m 。缺失位置由 M_m 标记。跨模态注意力只对有效 key/value 计算归一化权重；当某模态全部缺失时，注意力输出为零向量，避免全缺失输入产生伪均匀注意力。

对有效时间步进行 mask-aware pooling:

$$z_m = \frac{\sum_t M_m(t) H_m(t)}{\max(1, \sum_t M_m(t))}. \quad (4.5)$$

动态门控产生 g_t, g_a, g_v ，并满足 $g_t + g_a + g_v = 1$ 。融合表示为

$$z = g_t z_t + g_a z_a + g_v z_v. \quad (4.6)$$

分类头输出三类极性概率，回归头输出连续情感强度。

4.3 缺失建模与训练

本文区分三种情况：原始数据中的真实缺失、训练阶段随机模拟的局部连续缺失，以及附件 3 中的真实专项缺失。训练增强在统一时间轴上随机选择连续区间，将对应模态的输入和 mask 同步置为缺失。缺失类型包括文本、音频、视觉及双模态组合，缺失位置包括前段、中段和后段。

训练损失采用加权交叉熵与 Smooth L1 回归损失的加权和。结构消融分别去除跨模态注意力、动态门控、缺失增强和缺失 mask，保持数据划分、训练轮数和三个 seed 不变。

4.4 最终评估策略

三个 seed 分别保存验证集最佳 checkpoint。最终分类概率先求平均，再采用 Argmax:

$$\hat{c} = \arg \max_c \frac{1}{3} \sum_{s \in \{42, 123, 777\}} p_s(c). \quad (4.7)$$

最终测试指标为：Accuracy 66.30%，Macro-F1 62.54%，MAE 0.6346，Pearson $r = 0.6630$ 。普通交叉熵和 Focal Loss 仅作为验证阶段比较方案，不根据测试集选择损失。

表 4.5 最终模型与损失函数对照

方案	Accuracy	Macro-F1	MAE	Pearson r
加权交叉熵（最终）	66.30%	62.54%	0.6346	0.6630
普通交叉熵	67.54%	59.33%	0.6344	0.6675
Focal Loss	67.95%	60.96%	0.6284	0.6709

表 4.6 结构消融结果

模型	Accuracy	Macro-F1	MAE	Pearson r
Full DRM-Net	66.30%	62.54%	0.6346	0.6630
No Cross-Attention	66.16%	62.17%	0.6231	0.6723
No Dynamic Gate	66.16%	62.69%	0.6343	0.6597
No Missing Augmentation	64.65%	60.83%	0.6360	0.6646
No Missing Mask	65.75%	60.93%	0.6428	0.6541

4.5 结构消融

缺失增强和缺失 mask 的去除带来更明显的 Macro-F1 下降，支持二者对缺失场景建模的作用。该结论仅针对已运行的实验设置，不外推到未测试的缺失比例或数据分布。

4.6 附件 3 专项推理

附件 3 共输出两套各 30 条记录，字段包括样本编号、缺失模态、缺失区间、预测极性、预测强度、不确定度和三模态门控权重。由于附件 3 无标签，本文不计算准确率、F1、MAE 或 Pearson。

5 问题三：基于遮挡敏感性的多模态解释

5.1 解释对象与边界

问题三复用问题二中锁定的 DRM-Net 模型，对完整三模态输入进行预测和解释。解释结果描述模型输出对输入扰动的敏感程度，不等同于严格因果效应；门控权重也不等同于真实信息量。

5.2 模态遮挡敏感性

设完整输入的回归输出为 $\hat{y}$ ，遮挡模态 m 后的输出为 $\hat{y}^{(-m)}$ ，定义：

$$\Delta_m = |\hat{y} - \hat{y}^{(-m)}|, \quad C_m = \frac{\Delta_m}{\Delta_t + \Delta_a + \Delta_v + \epsilon}. \quad (5.8)$$

其中 C_m 是相对遮挡敏感性比例。由于模态交互和非线性重算， C_m 不能解释为独立的因果贡献。

5.3 时间步显著性与证据映射

在遮挡敏感性最大的主要模态内，对第 t 个时间步进行遮挡，得到：

$$S(t) = |\hat{y} - \hat{y}^{(-t)}|. \quad (5.9)$$

对 $S(t)$ 归一化后，使用连续窗口求和选择最大显著窗口，再按照原始视频时长映射到秒数和帧区间，并保存对应文本片段。

5.4 附件 4 结果

附件 4 共输出 20 条无标签记录，包含预测极性、预测强度、三模态遮挡后预测、遮挡敏感性比例、主要模态、时间步显著性序列、关键时间窗、视频帧区间和文本证据。由于没有真实标签，附件 4 不计算准确率或 F1。

解释结果统计显示，文本模态平均遮挡敏感性为 64.17%，音频为 17.33%，视觉为 18.50%；主要参考模态为文本 19 条、视觉 1 条、音频 0 条。该统计只描述当前 20 条专项样本和当前模型，不代表普遍因果规律。

5.5 问题三小结

本文形成了“完整预测—单模态遮挡—时间步遮挡—窗口定位—文本/视频映射”的可追溯解释链。解释 CSV 和图表均由模型重新计算的结果生成，最终解释应称为模态遮挡敏感性和时间步遮挡显著性。

6 三项任务的逻辑链、数据闭环与结论边界

本文将三个问题组织为一条可复核的数据链：题目要求与数据定义，特征提取与时间统一，完整模态基线，训练集局部缺失模拟，验证集模型与阈值选择，附件 3 专项推理，遮挡敏感性解释，以及附件 4 专项推理与证据定位。每个子问题均回答四个问题：输入数据是什么、模型如何处理、用什么指标验证、输出如何支持结论。

6.1 数据分层与信息使用边界

附件 1 的 100 条原始视频只用于问题一的特征提取与对齐；附件 2 按照 train/valid/test 组织，用于问题二和问题三的训练、模型选择与最终评估；附件 3 和附件 4 均为无标签专项测试集，只能在模型和阈值锁定后进行最终推理。标准化均值和标准差仅由训练集计算，并传递至验证集和测试集。

表 6.7 本文各类数据的用途与允许输出

数据	标签	用途	允许报告的结果
附件 1	有	问题一特征提取、对齐和完整性核验	样本覆盖、特征维度、有效长度、对齐记录
附件 2 训练集	有	参数学习、标准化统计量、缺失增强	训练损失和训练过程
附件 2 验证集	有	epoch、超参数和决策阈值选择	Accuracy、Macro-F1、MAE、Pearson r
附件 2 测试集	有	全部方案锁定后的最终一次评估	最终性能指标
附件 3	无	局部缺失专项推理	极性、强度、不确定度、缺失区间和门控权重
附件 4	无	完整模态解释专项推理	极性、强度、遮挡敏感性、关键时间和证据片段

6.2 问题一：从原始视频到统一时序特征

问题一的输入是视频、文本和标签三者的一一对应关系。文本经 BERT 编码得到 768 维上下文表示；音频由 MFCC、Chroma、Mel、频谱对比度和 Tonnetz 等声学统计量组成 74 维特征；视觉流由逐帧视觉统计量组成 35 维特征。音频和视觉的原始有效长度保存在汇总文件中，便于核验截断与填充。

设文本有效长度为 L_t ，音频和视觉原始序列为 X_a, X_v ，统一最大长度为 50，目标对齐长度为 $L = \min(L_t, 50)$ 。对模态 m 映射到文本时间轴的区间 I_k ，采用分段平均完成软

对齐:

$$\tilde{X}_m[k] = \frac{1}{|I_k|} \sum_{i \in I_k} X_m[i], \quad m \in \{a, v\}. \quad (6.10)$$

空区间使用相邻有效位置补偿,最后补零至 50 步,过长部分截断。问题一的交付重点不是预测准确率,而是 100 条样本的可追溯性:样本编号、原始路径、文本有效长度、音频/视觉有效长度、对齐后形状、标签和异常处理记录必须能够从 `problem1_feature_summary_100.csv` 核验。

6.3 问题二: 局部缺失、鲁棒预测与专项推理

训练阶段从完整训练样本构造连续缺失区间,缺失仅改变输入特征和对应 `mask`,不改变标签。模型首先将三种模态投影到统一隐空间,再使用 Bi-GRU 提取模态内上下文,通过缺失有效 `mask` 约束跨模态注意力,最后用门控权重融合三种模态:

$$z = g_t z_t + g_a z_a + g_v z_v, \quad g_t + g_a + g_v = 1. \quad (6.11)$$

分类和回归输出分别为

$$\hat{y}_c = \arg \max_j \text{softmax}(W_c z)_j, \quad \hat{y}_r = f_r(z). \quad (6.12)$$

验证集用于选择最佳 `epoch`、缺失实验配置和 BUDT 阈值;测试集不参与训练过程中的方案选择。完整输入与缺失输入的性能差异定义为

$$\Delta M = M_{\text{complete}} - M_{\text{missing}}. \quad (6.13)$$

消融结果按缺失模态、缺失位置和缺失时长分别报告 `Accuracy`、`Macro-F1`、`MAE` 和 `Pearson r`,并同时给出缺失比例。附件 3 无标签,只汇总预测极性、预测强度、缺失区间、不确定度和三模态门控权重,不计算准确率或 F1。

6.4 问题三: 遮挡敏感性与局部证据定位

问题三复用已锁定的预测模型,对完整三模态输入进行可复核扰动。设完整输入回归输出为 $\hat{y}$,遮挡模态 m 后的输出为 $\hat{y}^{(-m)}$,定义模态遮挡敏感性为

$$\Delta_m = |\hat{y} - \hat{y}^{(-m)}|, \quad C_m = \frac{\Delta_m}{\Delta_t + \Delta_a + \Delta_v + \varepsilon}. \quad (6.14)$$

其中 C_m 表示相对作用程度,而不是严格独立的因果效应,因为三种模态存在交互。在作用程度最大的模态内逐时间步遮挡,定义局部敏感性 $S(t) = |\hat{y} - \hat{y}^{(-t)}|$,再使用连续窗口求和选择最大证据窗口,并映射到原始视频秒数、帧区间和文本片段。

附件 4 每条记录至少保存预测极性、强度、三模态遮挡敏感性、作用比例、主要模态、显著性序列、关键时间步、视频帧和文本证据。论文中的解释应称为遮挡敏感性或反事实扰动贡献,不能直接表述为严格因果效应。

6.5 数据闭环与结论边界

论文中的每一个数字都应能追溯到对应的 CSV、JSON 或 PNG 输出。附件 3 和附件 4 的专项结果只能作为无标签推理展示，不能作为性能验证；门控权重只能解释为模型内部的动态分配，不等价于真实信息量。最终结论应同时报告模型性能、缺失条件、解释方法及其局限性，避免以单一最优指标代替完整实验链。

7 实验分析、局限性与结论

7.1 实验完整性

本文所有最终模型选择均在验证集完成。测试集只在最终方案固定后评估一次；附件 3 和附件 4 为无标签专项测试集，只进行推理。三个 seed 为 42、123、777，最终分类采用三 seed 概率平均后的 Argmax。

7.2 主要结果

最终加权交叉熵 DRM-Net 在测试集上的 Accuracy 为 66.30%，Macro-F1 为 62.54%，MAE 为 0.6346，Pearson r 为 0.6630。普通交叉熵和 Focal Loss 的 Accuracy 较高，但 Macro-F1 较低，因此最终方案优先保留类别平衡更好的加权交叉熵结果。

7.3 结构消融结论

去除缺失增强后 Accuracy 降至 64.65%，Macro-F1 降至 60.83%；去除缺失 mask 后 Accuracy 降至 65.75%，Macro-F1 降至 60.93%。这说明显式缺失建模是当前模型鲁棒性的主要来源之一。跨模态注意力和动态门控的作用通过独立结构消融报告，不将单一指标解释为绝对优越性。

7.4 误差与解释边界

验证集错误主要集中在弱情感混淆、中性边界漂移和严重极性倒置。由于情感标签具有主观性，模型在中性附近存在不可完全消除的歧义。模态遮挡敏感性反映的是模型输出对输入扰动的响应，受模态交互、遮挡方式和模型参数影响，不能作为严格因果证明。

7.5 局限性

第一，当前实验结论只覆盖已经实际运行的缺失类型、位置和比例，不能外推到未测试的极端丢包条件。第二，附件 3 和附件 4 没有标签，专项结果不能用于性能验证。第三，当前解释方法是遮挡重算，不是积分梯度或 Attention Rollout。第四，统一长度处理是工程化时间索引，不等价于动态时间规整，因此不声称获得 DTW 的理论保证。

7.6 结论

本文完成了从三模态特征提取、时间统一、局部缺失鲁棒训练，到无标签专项预测和遮挡敏感性解释的完整流程。代码、CSV、JSON 和图表均保留了样本级追溯信息，最终结论以当前冻结的实验结果为准。